大模型导论知识点测验

基于课程知识点的全面练习题集

zyh

2026 年 1 月 7 日

摘要

这是一份针对《大模型导论》课程所设计的综合性测试题，包含大约200道精心编制的题目。题库涵盖填空题、单项选择题、多项选择题、简答题、判断题、程序分析题和计算题七种题型，全面覆盖课程核心知识点。

1 填空题

1. _____是一种通过在输入中添加特定标记来引导模型行为的技术。
2. PEFT技术起源于Google公司在论文"Parameter-Efficient Transfer Learning for NLP"中提出的一种对BERT模型的高效参数微调策略，该策略是_____。
3. _____是一种用于加速大模型推理的技术，通过减少参数精度来降低计算开销。
4. _____是一种用于评估大模型性能的基准测试。
5. 大模型预训练通常使用_____数据，而微调则使用特定任务的标注数据。
6. _____是Google于2023年发布的多模态大模型。
7. 大模型的_____是指模型对未见过的数据做出合理预测的能力。
8. 在大模型训练中，_____用于防止模型过拟合训练数据。
9. _____是Meta于2023年发布的开源大语言模型系列。
10. _____是一种将大模型知识迁移到小模型的技术。
11. _____是Google于2018年发布的基于Transformer的预训练语言模型。
12. _____是一种通过调整模型输入来引导模型输出的技术。
13. 大模型很难在单个_____上进行预训练，需要使用分布式训练技术。
14. 大模型的_____是指模型能够理解和生成连贯、自然的文本的能力。
15. _____是一种用于评估大模型安全性的重要指标。
16. 大模型技术发展初期（2013年前），处理序列数据的主流模型是_____和_____
17. 大模型的开发流程包括数据准备、模型设计、模型训练、_____和模型应用。
18. _____是一种参数高效微调技术，通过低秩分解来减少微调参数量。
19. _____是Google于2023年发布的大型语言模型系列。
20. _____是一种通过添加小型适配器模块来进行参数高效微调的技术。
21. _____是一种通过比较模型输出与参考答案来评估文本生成质量的指标。
22. 大模型属于_____模型，是一种参数量巨大的神经网络模型。
23. _____年，OpenAI发布了引发AI浪潮的ChatGPT。
24. _____是一种用于处理长序列的注意力机制变体。
25. _____是OpenAI于2024年发布的文生视频模型。
26. _____是一种通过在训练过程中随机丢弃部分神经元来防止过拟合的技术。
27. 在Transformer中，_____层用于对特征进行非线性变换。
28. _____是一种通过预先计算部分结果来加速大模型推理速度的技术。

29. _____是一种用于减少大模型内存占用的技术，通过共享参数来实现。
30. Word2Vec是Google于_____年提出的一种高效训练词向量的模型。
31. 在Transformer中，_____用于将多个注意力头的输出合并。
32. _____是一种通过人类反馈来优化大模型输出的技术。
33. _____是一种通过预先计算部分结果来加速大模型推理速度的技术。
34. 在自然语言处理中，_____是指模型在没有见过特定任务示例的情况下完成任务的能力。
35. _____是Google于2017年提出的一种高效训练词向量的模型。
36. _____是OpenAI于_____年发布的文生视频大模型。
37. GPT-1于_____年发布，参数量为1.1亿。
38. 大模型的_____能力使其能够处理多种不同的任务而无需重新训练。
39. 大模型的_____是指模型在不同领域和任务上表现出的泛化能力。
40. 在Transformer中，_____层用于将输入序列转换为特征表示。
41. Sora是OpenAI于_____年发布的文生视频大模型。
42. GPT-4 Turbo支持用户_____构建自定义GPT。
43. 残差连接主要用于缓解深度神经网络中的_____问题。
44. AIGC的全称是_____，代表了人工智能生成内容的新趋势。
45. 大模型的_____是指模型能够理解和遵循人类指令的能力。
46. 大模型的_____能力使其能够根据少量示例学习新任务。
47. GPT-3的参数量达到了_____亿。
48. BERT模型的全称是_____。
49. 与传统模型相比，大模型的参数规模通常达到_____级、_____级甚至_____级。
50. 大模型训练通常需要使用_____、_____等分布式训练技术。
51. 空间域去噪方法是指通过不同的图像平滑模板对原始图像进行_____处理的方法。
52. 知识蒸馏中，学生模型的目标是模仿教师模型的_____。
53. 在Transformer中，_____用于将特征映射回输出空间。
54. 在自注意力机制中，_____用于计算查询与键的相似度。
55. Transformer模型中引入_____来保留序列中Token的顺序信息。
56. 自注意力机制的计算复杂度与序列长度成_____关系。
57. 大模型技术发展初期（2013年前），处理序列数据的主流模型是_____和_____

58. 2023年GPT-4V等大模型的突破方向是将大模型从语言模型引向_____模型。
59. Transformer模型中，残差连接用于缓解_____问题。
60. 在大模型中，文本的最小处理单位是_____。

2 单项选择题

1. 以下哪个不是大模型技术发展的阶段？
   A. 发展初期(2013年前)
   B. 探索期(2013-2018)
   C. 兴起期(2019-2021)
   D. 衰退期(2022至今)
2. 大模型与传统人工智能模型的核心差异在于？
   A. 传统模型参数量更大
   B. 大模型仅需少量标注数据即可训练
   C. 大模型需海量数据预训练且泛化能力更强
   D. 传统模型支持多任务微调
3. 以下哪个是用于评估大模型多语言能力的基准？
   A. GLUE
   B. XTREME
   C. ImageNet
   D. MNIST
4. 以下哪个不是大模型的应用场景？
   A. 内容创作
   B. 代码生成
   C. 物理实验模拟
   D. 智能客服
5. GPT-3的参数量大约是多少？
   A. 1.5亿
   B. 15亿
   C. 1750亿
   D. 1.75万亿
6. 数据并行训练中，梯度同步通常使用什么操作？
   A. All-Reduce
   B. Broadcast
   C. Scatter
   D. Gather
7. BERT模型的主要创新点是什么？
   A. 引入了自注意力机制
   B. 采用了双向编码器结构
   C. 实现了多模态处理
   D. 降低了模型参数量

8. 以下哪个是Google开发的大模型？
   A. GPT-4
   B. LLaMA
   C. PaLM
   D. ChatGLM
9. 以下哪项不是大模型训练面临的挑战？
   A. 计算资源需求高
   B. 数据质量要求高
   C. 单GPU即可完成训练
   D. 训练时间长
10. Foundation Model（基础模型）的典型特征不包括？
   A. 依赖海量数据预训练
   B. 专精单一任务且泛化能力弱
   C. 参数量达十亿级及以上
   D. 需要 GPU集群分布式训练
11. 以下哪个模型是纯Decoder架构？
   A. BERT
   B. GPT-3
   C. T5
   D. BART
12. 以下哪个模型是在2023年发布的开源大语言模型？
   A. GPT-3
   B. BERT
   C. LLaMA
   D. Word2Vec
13. 大模型训练中，DeepSpeed主要用于解决什么问题？
   A. 提高模型精度
   B. 分布式训练优化
   C. 减少训练数据需求
   D. 加速推理过程
14. 以下哪个是Meta公司开发的大模型系列？
   A. GPT
   B. LLaMA
   C. PaLM
   D. Gemini
15. 以下哪个不是大模型的典型应用场景？
   A. 文本生成

B. 图像识别
C. 视频编辑
D. 物理实验模拟

16. Sora模型的主要功能是什么？
A. 文本生成
B. 图像生成
C. 视频生成
D. 音频生成

17. Transformer架构的核心创新为？
A. 引入双向 LSTM解决多义词问题
B. 采用自注意力机制和位置编码实现并行计算
C. 将参数规模提升至千万级
D. 专门用于图像识别任务

18. 以下哪项技术用于减少大模型推理时的内存占用？
A. 模型量化
B. 增加参数量
C. 使用更高精度的数据类型
D. 减少序列长度

19. BERT模型属于哪种预训练语言模型？
A. 自回归模型
B. 自编码模型
C. 生成式模型
D. 判别式模型

20. 在 PyTorch中，用于计算梯度的函数是？
A. backward()
B. gradient()
C. compute_grad()
D. grad()

21. 以下哪个是用于评估大模型语言理解能力的基准？
A. GLUE
B. ImageNet
C. COCO
D. MNIST

22. 大模型"对齐"问题主要关注什么？
A. 使模型输出符合人类价值观和意图
B. 提高模型训练速度
C. 减少模型参数量

D. 优化硬件资源利用

23. 以下哪个不是大模型推理优化技术？

A. 模型量化

B. 缓存机制

C. 知识蒸馏

D. 增加参数量

24. 以下哪项不是参数高效微调(PEFT)方法？

A. LoRA

B. Prompt Tuning

C. Adapter

D. 全参数微调

25. 以下哪项技术可以减少大模型训练时的通信开销？

A. 梯度压缩

B. 增加通信频率

C. 使用更高带宽网络

D. 减少模型并行度

26. 大模型的”涌现能力”通常在什么情况下出现？

A. 模型规模达到一定阈值后

B. 使用特定类型的训练数据

C. 降低模型复杂度时

D. 减少训练轮次时

27. 以下哪项不是大模型的潜在风险？

A. 生成有害内容

B. 偏见放大

C. 过度拟合训练数据

D. 提高内容创作效率

28. 大模型的”zero-shot learning”指的是？

A. 模型在没有见过特定任务示例的情况下完成任务

B. 模型不需要任何训练就能工作

C. 模型参数为零

D. 模型只能处理零值输入

29. 以下哪个是用于大模型参数高效微调的技术？

A. LoRA

B. 全参数微调

C. 重新训练

D. 数据增强

30. 大模型训练中的”梯度累积”技术主要用于？

A. 在有限硬件条件下模拟更大的批次大小
B. 减少训练时间
C. 提高模型精度
D. 防止过拟合

31. 大模型的"上下文学习"能力指的是？
A. 模型通过上下文中的示例学习新任务
B. 模型只能在特定上下文中工作
C. 模型对上下文长度的依赖
D. 模型在训练时使用的上下文数据

32. 以下哪个不是Transformer的组成部分？
A. 自注意力层
B. 前馈神经网络
C. 循环单元
D. 位置编码

33. 大模型"幻觉"问题指的是什么？
A. 模型生成看似合理但不准确或虚构的信息
B. 模型对输入数据的过度敏感
C. 模型在训练过程中的随机波动
D. 模型无法处理长序列

34. 以下哪项不是大模型训练中的常见优化技术？
A. 梯度裁剪
B. 学习率预热
C. 增加过拟合
D. 权重衰减

35. 大模型训练中的"混合精度训练"主要目的是：
A. 加快训练速度并减少内存占用
B. 提高模型精度
C. 增加模型参数量
D. 减少训练数据需求

36. 以下哪项技术可以提高大模型处理长文本的能力？
A. 位置编码改进
B. 减少注意力头数量
C. 降低模型维度
D. 使用更小的批次大小

37. 大模型的"温度参数"在生成过程中主要影响：
A. 生成文本的随机性和创造性
B. 模型训练速度

C. 模型参数量

D. 硬件资源使用

38. 以下哪个不是大模型推理优化技术？

A. 模型量化

B. 缓存机制

C. 知识蒸馏

D. 增加参数量

39. 大模型的”少样本学习”能力指的是？

A. 模型能够根据少量示例学习新任务

B. 模型只需要少量数据就能训练

C. 模型参数量较少

D. 模型推理速度较快

40. 以下哪项不是参数高效微调(PEFT)方法？

A. LoRA

B. Prompt Tuning

C. Adapter

D. 全参数微调

41. 以下哪项技术可以减少大模型训练时的通信开销？

A. 梯度压缩

B. 增加通信频率

C. 使用更高带宽网络

D. 减少模型并行度

42. 大模型的”涌现能力”通常在什么情况下出现？

A. 模型规模达到一定阈值后

B. 使用特定类型的训练数据

C. 降低模型复杂度时

D. 减少训练轮次时

43. 大模型”对齐”问题主要关注：

A. 使模型输出符合人类价值观和意图

B. 提高模型训练速度

C. 减少模型参数量

D. 优化硬件资源利用

44. 以下哪个是用于评估大模型语言理解能力的基准？

A. GLUE

B. ImageNet

C. COCO

D. MNIST

45. 大模型训练中的”混合精度训练”主要目的是：
    A. 加快训练速度并减少内存占用
    B. 提高模型精度
    C. 增加模型参数量
    D. 减少训练数据需求
46. 以下哪个不是大模型的典型应用场景？
    A. 文本生成
    B. 图像识别
    C. 视频编辑
    D. 物理实验模拟
47. 大模型的”zero-shot learning”指的是：
    A. 模型在没有见过特定任务示例的情况下完成任务
    B. 模型不需要任何训练就能工作
    C. 模型参数为零
    D. 模型只能处理零值输入
48. 以下哪个是用于大模型参数高效微调的技术？
    A. LoRA
    B. 全参数微调
    C. 重新训练
    D. 数据增强
49. 大模型训练中的”梯度累积”技术主要用于：
    A. 在有限硬件条件下模拟更大的批次大小
    B. 减少训练时间
    C. 提高模型精度
    D. 防止过拟合
50. 大模型的”上下文学习”能力指的是：
    A. 模型通过上下文中的示例学习新任务
    B. 模型只能在特定上下文中工作
    C. 模型对上下文长度的依赖
    D. 模型在训练时使用的上下文数据
51. 以下哪个不是Transformer的组成部分？
    A. 自注意力层
    B. 前馈神经网络
    C. 循环单元
    D. 位置编码
52. 大模型”幻觉”问题指的是什么？
    A. 模型生成看似合理但不准确或虚构的信息

B. 模型对输入数据的过度敏感
C. 模型在训练过程中的随机波动
D. 模型无法处理长序列

53. 以下哪项不是大模型训练中的常见优化技术？
A. 梯度裁剪
B. 学习率预热
C. 增加过拟合
D. 权重衰减

54. 以下哪项技术可以提高大模型处理长文本的能力？
A. 位置编码改进
B. 减少注意力头数量
C. 降低模型维度
D. 使用更小的批次大小

55. 大模型的"温度参数"在生成过程中主要影响：
A. 生成文本的随机性和创造性
B. 模型训练速度
C. 模型参数量
D. 硬件资源使用

56. 以下哪个年份标志着大模型技术进入"井喷期"？
A. 2013年
B. 2017年
C. 2019年
D. 2022年

57. Word2Vec模型的基本假设是什么？
A. 上下文相似的词具有相似的词向量
B. 词的顺序不影响其语义
C. 所有词的向量长度相同
D. 词向量只能通过监督学习获得

58. 大模型训练中，DeepSpeed主要用于解决什么问题？
A. 提高模型精度
B. 分布式训练优化
C. 减少训练数据需求
D. 加速推理过程

59. 大模型的"指令微调"主要目的是什么？
A. 提高模型对人类指令的理解和遵循能力
B. 减少模型参数量
C. 加快训练速度

D. 降低推理延迟

60. 以下哪个模型是基于Encoder-Decoder架构的？

A. BERT

B. GPT-3

C. T5

D. RoBERTa

3 多项选择题

1. 以下哪些是大模型训练中常用的分布式训练技术？（）

A. DeepSpeed

B. Megatron-LM

C. TensorFlow

D. PyTorch

2. 以下哪些是Transformer架构的组成部分？（）

A. 自注意力机制

B. 位置编码

C. 循环单元

D. 前馈神经网络

3. 关于注意力机制的描述，正确的是？（）

A. 模仿人类视觉选择性关注重要信息

B. 仅适用于文本序列处理

C. 自注意力可建立序列元素间的长程依赖

D. 矩阵V代表元素的关键特征信息

4. 以下哪些是大模型开发流程的组成部分？（）

A. 数据准备

B. 模型设计

C. 模型训练

D. 模型评估

5. 以下哪些是RLHF（基于人类反馈的强化学习）的步骤？（）

A. 监督微调

B. 奖励模型训练

C. 强化学习优化

D. 模型蒸馏

6. 关于多头注意力机制的以下描述，哪些是正确的？（）

A. 多个注意力头独立计算，每个头学习不同的语义子空间表示

B. 多头注意力的计算复杂度与头数成正比，增加头数会显著增加计算开销

C. 多头注意力的输出通常是多个头输出的拼接，然后通过线性变换统一维度

D. 在 Transformer 中，编码器和解码器的多头注意力层结构完全相同

7. 以下哪些是大模型"幻觉"问题的可能解决方案？（）

A. 改进训练数据质量

B. 使用检索增强生成(RAG)

C. 优化模型对齐

D. 提高模型不确定性表达

8. 以下哪些是AIGC带来的影响？（）

A. 提高内容生产效率

B. 降低创作门槛

C. 促进多模态内容融合

D. 改变PGC和UGC模式

9. 关于预训练语言模型类型，正确的描述有？（）

A. 自回归语言模型仅利用上文信息进行下一个词元的预测

B. ELMo虽然使用双向信息，但本质上属于自回归模型

C. 自编码语言模型在预训练阶段使用MASK符号掩码，微调阶段则不用

D. GPT系列模型属于自编码语言模型

10. 以下哪些是大模型评估的重要指标？（）

A. 任务准确率

B. 推理速度

C. 有害内容生成率

D. 人类偏好对齐度

11. 以下哪些技术可以优化大模型推理性能？（）

A. 模型量化

B. 缓存机制

C. 知识蒸馏

D. 梯度裁剪

12. 以下哪些是大模型训练中常用的正则化技术？（）

A. Dropout

B. 权重衰减

C. 梯度裁剪

D. 模型量化

13. 以下哪些是大模型未来发展的主要方向？（）

A. 多模态/跨模态

B. 工具化生态

C. 智能体进化

D. 减少参数量

14. 以下哪些是Transformer模型中Encoder的组成部分？（）
    A. 自注意力层
    B. 前馈神经网络
    C. 位置编码
    D. 残差连接
15. 以下哪些是大模型预训练的优点？（）
    A. 利用海量无标注数据
    B. 学习通用语言表示
    C. 减少下游任务标注需求
    D. 提高模型泛化能力
16. 以下哪些是大模型”涌现能力”的典型表现？（）
    A. 少样本学习能力
    B. 推理能力
    C. 代码生成能力
    D. 语言翻译能力
17. 以下哪些是大模型安全与伦理方面的挑战？（）
    A. 生成有害内容
    B. 偏见放大
    C. 隐私泄露
    D. 模型参数量大
18. 以下哪些是用于评估大模型性能的基准测试？（）
    A. GLUE
    B. MMLU
    C. ImageNet
    D. XTREME
19. 以下哪些是大模型训练中的优化策略？（）
    A. 混合精度训练
    B. 梯度累积
    C. 学习率预热
    D. 模型量化
20. 以下哪些是大模型指令微调的目的？（）
    A. 提高模型对人类指令的理解
    B. 使模型输出更符合人类偏好
    C. 减少模型参数量
    D. 使模型更安全可靠
21. 以下哪些是大模型处理多模态数据的方式？（）
    A. 多模态编码器

B. 模态对齐
C. 统一表示空间
D. 单模态处理

22. 以下哪些是大模型中常见的注意力机制变体？（）
A. 稀疏注意力
B. 线性注意力
C. 旋转位置编码
D. 残差连接

23. 以下哪些是大模型训练中常用的数据预处理技术？（）
A. 文本清洗
B. 分词
C. 数据去重
D. 梯度裁剪

24. 以下哪些是大模型与传统AI模型的区别？（）
A. 参数规模更大
B. 依赖更多训练数据
C. 计算要求更高
D. 泛化能力更强

25. PEFT技术适用于以下哪些场景（）
A. 硬件资源受限的个人开发者
B. 需要快速适配新任务的团队
C. 要求全量参数更新的高精度任务
D. 小型科研团队

4 简答题

1. 简述大模型面临的计算挑战及其解决方案。
2. 简述大模型技术发展的四个时期及其代表性模型（列出不少于 3个）。
3. 解释大模型中的”位置编码”作用及其不同类型。
4. 简述大模型在AIGC领域带来的变革及其影响。
5. 解释大模型中的”幻觉”问题及其可能的解决方案。
6. 简述大模型与传统人工智能模型的主要区别。
7. 画出Transformer整体结构。
8. 简述预训练的三大优点。
9. 解释大模型中的”多模态”概念及其发展意义。
10. 为什么Transformer架构比RNN更适合大模型训练？
11. 简述大模型开发流程的五个主要阶段及其关键任务。

12. 解释大模型中的”涌现能力”概念及其重要性。
13. 简述RLHF（基于人类反馈的强化学习）在大模型训练中的作用和流程。
14. 解释大模型中的”指令微调”概念及其重要性。
15. 解释大模型中的”参数高效微调”(PEFT)技术及其主要优势。
16. LoRA的基本设计思路是什么？如何实现？
17. 简述大模型对内容创作行业的影响和挑战。
18. 简述大模型评估的主要维度和常用方法。
19. 解释大模型中的”上下文学习”(In-Context Learning)能力。
20. 简述大模型在AI智能体发展中的作用。

5 判断题

1. BERT是一种Decoder-only架构的模型。
2. Word2Vec是Google于2017年提出的词向量模型。
3. 残差连接主要用于解决Transformer中的梯度消失问题。
4. 大模型预训练阶段主要使用标注数据进行训练。
5. 大模型的zero-shot能力是指模型需要大量示例才能完成任务。
6. 适配器(Adapter)是一种参数高效微调技术。
7. 在图像预处理中，中值滤波是一种线性滤波方法。
8. 大模型的涌现能力是指随着模型规模增大而线性提升的能力。
9. 大模型开发流程不包括模型评估阶段。
10. Sora是Meta公司于2023年发布的文生视频模型。
11. AIGC代表”Artificial Intelligence General Computing”。
12. 大模型”幻觉”是指模型生成虚假但看似合理的信息。
13. 大模型训练中的混合精度训练使用FP16和FP32混合计算。
14. GPT-3的参数量达到了1750亿。
15. Transformer架构中，位置编码用于解决自注意力机制无法感知序列顺序的问题。
16. 模型量化是一种通过降低参数精度来减少模型大小和计算开销的技术。
17. LoRA是一种全参数微调技术。
18. RLHF是”Reinforcement Learning from Human Feedback”的缩写。
19. KV Cache技术通过缓存上一轮推理的 Key和 Value向量来减少当前轮次的计算量。
20. PyTorch的 DataLoader可以实现自动将数据集分批并打乱顺序。

6 程序分析题

1. 现有代码如下：

```
import torch
x = torch.tensor([1.0, 2.0], requires_grad=True)
y = torch.relu(x)
z = y.sum()
z.backward()
print("x.grad=", x.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数z(x)的梯度值。

2. 现有代码如下：

```
import torch
x = torch.tensor(1.0, requires_grad=True)
y = x ** 3
z = torch.log(y)
z.backward()
print("x.grad=", x.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数z(x)的梯度值。

3. 现有代码如下：

```
import torch
a = torch.tensor([2.0], requires_grad=True)
b = torch.tensor([3.0], requires_grad=True)
c = a * b
d = c ** 2
d.backward()
print("a.grad=", a.grad)
print("b.grad=", b.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数d(a,b)的梯度值。

4. 现有代码如下：

```
import torch
x = torch.tensor([0.5, 1.0], requires_grad=True)
w = torch.tensor([2.0, 3.0], requires_grad=True)
y = torch.dot(x, w)
y.backward()
```

```
print("x.grad=", x.grad)
print("w.grad=", w.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数y(x,w)的梯度值。

5. 现有代码如下：

```
import torch
x = torch.tensor([1.0, 2.0], requires_grad=True)
y = x * x
z = y.sum()
z.backward()
print("x.grad=", x.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数z(x)的梯度值。

6. 现有代码如下：

```
import torch
x = torch.tensor(1.0, requires_grad=True)
y = torch.tensor(2.0, requires_grad=True)
z = x * y + torch.sin(x)
z.backward()
print("x.grad=", x.grad)
print("y.grad=", y.grad)
```

(1) print函数输出结果是什么？ (2) 请用链式法则手动推导函数z(x,y)的梯度值。

7 计算题

1. 将7B参数的大模型从FP32量化到INT8，计算量化后模型参数所需的存储空间（MB，保留整数），并计算理论压缩率。
2. 一个大模型有1750亿参数，使用FP16精度存储。计算存储该模型所需的最小显存（以GB为单位，1GB=10^9字节）。
3. 已知自注意力机制中Q、K、V矩阵分别为： Q = [[1, 0], [0, 1]] K = [[0, 1], [1, 0]] V = [[2, 0], [0, 2]] 计算注意力输出（假设缩放因子为$\sqrt{2}$）。
4. 假设一个Transformer模型有12层，每层有12个注意力头，每个头的维度为64。计算该模型中注意力机制的总参数量（不考虑其他组件）。

5. 一个大模型在单GPU上训练需要10天，使用8个GPU进行数据并行训练。假设理想情况下，计算速度与GPU数量成正比，且通信开销可以忽略。计算使用8个GPU训练所需的时间。
6. 假设一个大模型有100亿参数，使用Adam优化器进行训练。计算训练过程中需要额外存储的优化器状态的大小（以GB为单位，1GB=10^9字节）。提示：Adam需要存储每个参数的动量和方差。
7. 假设一个Transformer模型的输入序列长度为512，嵌入维度为768。计算自注意力机制中QK^T矩阵的大小（元素数量）。

8 Tips

1. 试题仅仅是对所学知识的测验，最终还是希望同学们能认真复习书上的知识点，弄清搞懂熟记，如此方能考试无忧！
2. 考试做题时要仔细，不要着急交卷。认真对待每一题，这样分数才会认真对待你！
3. 建议带一支铅笔和一个橡皮用来画图。
4. 强烈建议大家把书上的示例代码都调一调，跑一跑，会有新的感悟（可以考试后弄）。
5. 无论哪门课，在学习过程中一定要善用AI工具和教学视频！
6. 这门课程只是一个开始，希望大家能够持续学习，拥抱AI时代。

最后祝同学们都能考出理想成绩，加油！